mooc mertes

June 15, 2023

```
[]: import pandas as pd
    import numpy as np
    import matplotlib.pyplot as plt
    import seaborn as sns
    import statsmodels.api as sm
    from statsmodels.graphics.mosaicplot import mosaic
    from statsmodels.formula.api import ols
    from statsmodels.formula.api import logit
    from statsmodels.formula.api import glm
    from statsmodels.api import qqplot
    from scipy.stats import ttest_ind as t_student
    from scipy.stats import mannwhitneyu
    from scipy.stats import chi2_contingency
    from scipy.stats import pearsonr
    from scipy.stats import spearmanr
    from scipy.stats import kstest
    from scipy.stats import norm
    from matplotlib.patches import Rectangle
[]: # Chargement des données
    effec1 = pd.read_csv("../csv/effec1.quest.compil.csv", encoding="ISO-8859-1")
    effec2 = pd.read_csv("../csv/effec2.quest.compil.csv", encoding="ISO-8859-1")
    effec3 = pd.read_csv("../csv/effec3.quest.compil.csv", encoding="ISO-8859-1")
    usage1 = pd.read_csv("../csv/usages.effec1.csv", encoding="ISO-8859-1")
    usage2 = pd.read_csv("../csv/usages.effec2.csv", encoding="ISO-8859-1")
    usage3 = pd.read_csv("../csv/usages.effec3.csv", encoding="ISO-8859-1")
[]: usage3.info()
    <class 'pandas.core.frame.DataFrame'>
    RangeIndex: 3883 entries, 0 to 3882
    Data columns (total 76 columns):
         Column
                                Non-Null Count Dtype
    --- ----
                                _____
         Student ID
                               3883 non-null
                                                int64
                               843 non-null
                                                float64
     1
         Exam.score
         Exam.bin
                                3883 non-null
                                                int64
```

3	Assignment.score	838 non-null	float64
4	Assignment.bin	3883 non-null	int64
5	Quizz.1.score	1774 non-null	float64
6	Quizz.1.bin	3883 non-null	int64
7	Quizz.2.score	1295 non-null	float64
8	Quizz.2.bin	3883 non-null	int64
9	Quizz.3.score	1069 non-null	float64
10	Quizz.3.bin	3883 non-null	int64
11	Quizz.4.bin	3883 non-null	int64
12	Quizz.4.score	973 non-null	float64
13	Quizz.5.bin	3883 non-null	int64
14	Quizz.5.score	911 non-null	float64
15	Intro.MOOC	0 non-null	float64
16	Prez.sem.1	3883 non-null	int64
17	S1.L1	3883 non-null	int64
18	S1.L2	3883 non-null	int64
19	S1.L3	3883 non-null	int64
20	S1.L4	3883 non-null	int64
21	S1.L5	3883 non-null	int64
22	S1.L6	3883 non-null	int64
23	Prez.sem.2	3883 non-null	int64
24	S2.L1	3883 non-null	int64
25	S2.L2	3883 non-null	int64
26	S2.L3	3883 non-null	int64
27	S2.L4	3883 non-null	int64
28	S2.L5	3883 non-null	int64
29	S2.L6	3883 non-null	int64
30	Prez.sem.3	3883 non-null	int64
31	S3.L1.1	3883 non-null	int64
32	S3.L1.2	3883 non-null	int64
33	S3.L2	3883 non-null	int64
34	S3.L3	3883 non-null	int64
35	S3.L4	3883 non-null	int64
36	S3.L5	3883 non-null	int64
37	Prez.sem.4	3883 non-null	int64
38	S4.L1.1	3883 non-null	int64
39	S4.L1.2	3883 non-null	int64
40	S4.L2	3883 non-null	int64
41	S4.L3	3883 non-null	int64
42	S4.L4	3883 non-null	int64
43	S4.L5	3883 non-null	int64
44	Prez.sem.5	3883 non-null	int64
45	S5.L1.1	3883 non-null	int64
46	S5.L1.2	3883 non-null	int64
47		3883 non-null	int64
48	S5.L3	3883 non-null	int64
49	S5.L4	3883 non-null	int64
50	S5.L5	3883 non-null	int64

```
51 Post.forum.0
                            3883 non-null
                                             int64
 52
    view.forum.0
                            3883 non-null
                                             int64
 53
    Post.forum.1
                            3883 non-null
                                             int64
54 Post.forum.1.2
                            3883 non-null
                                             int64
    view.forum.1
 55
                            3883 non-null
                                             int64
 56
    view.forum.1.2
                            3883 non-null
                                             int64
 57
    Post.forum.2
                            3883 non-null
                                             int64
 58 Post.forum.2.2
                            3883 non-null
                                             int64
    view.forum.2
                            3883 non-null
                                             int64
    view.forum.2.2
                            3883 non-null
 60
                                             int64
61 Post.forum.3
                            3883 non-null
                                             int64
    view.forum.3
                            3883 non-null
 62
                                             int64
63 Post.forum.4
                            3883 non-null
                                             int64
 64
    Post.forum.4.2
                            3883 non-null
                                             int64
    view.forum.4
                            3883 non-null
                                             int64
    view.forum.4.2
                            3883 non-null
                                             int64
    Post.forum.5
                            3883 non-null
                                             int64
    Post.forum.5.2
 68
                            3883 non-null
                                             int64
 69
    view.forum.5
                            3883 non-null
                                             int64
 70
    view.forum.5.2
                            3883 non-null
                                             int64
    last.video
 71
                            3883 non-null
                                             int64
 72
    last.quizz
                            3883 non-null
                                             int64
    Assignment.choice
                            3883 non-null
                                             int64
 74 Post.forum.fonc.cours
                            3883 non-null
                                             int64
75 view.forum.fonc.cours
                            3883 non-null
                                             int64
dtypes: float64(8), int64(68)
memory usage: 2.3 MB
```

[]: effec3.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 4233 entries, 0 to 4232
Data columns (total 26 columns):

#	Column	Non-Null Count	Dtype
0	Student_ID	3883 non-null	float64
1	Certif.bin	3883 non-null	float64
2	Section	1587 non-null	object
3	Gender	1577 non-null	object
4	birth.year	1543 non-null	float64
5	Country	1575 non-null	object
6	Diploma	1574 non-null	object
7	EMLYON.et	1567 non-null	object
8	Formation	1562 non-null	object
9	CSP	1572 non-null	object
10	How.heard	1571 non-null	object
11	Exp.crea	1570 non-null	object
12	Curiosity.MOOC	1569 non-null	object

```
13 Certif.self.sat
                      1561 non-null
                                      float64
14 Rencontres
                      1551 non-null
                                      object
15
   Certif.work
                      1562 non-null
                                      float64
16 Incitation
                      1564 non-null
                                      float64
   Temps.Dispo
17
                      1561 non-null
                                      object
   Exp.MOOC
                      1556 non-null
                                      object
   Completion.proba
                                      float64
                      1559 non-null
20
   EMLyon
                      1567 non-null
                                      object
21
   Country_HDI
                      1562 non-null
                                      object
22
   Country_HDI.fin
                      1562 non-null
                                      object
23
   age
                      1543 non-null
                                      float64
24
   CSP.fin
                      1572 non-null
                                      object
25 Temps.dispo.fin
                      1561 non-null
                                      object
```

dtypes: float64(8), object(18)

memory usage: 860.0+ KB

[]: usage1.head()

		•								
[]:		Student_ID Ex	kam.score Exam	n.bin	Assignmen	t.score	Assign	nment.bin	\	
	0	28	NaN	0		NaN		0		
	1	36	NaN	0		NaN		0		
	2	45	NaN	0		NaN		0		
	3	83	NaN	0		60.0		1		
	4	84	NaN	0		NaN		0		
		Quizz.1.score	Quizz.1.bin	Quizz	.2.score	Quizz.2.h	oin Qu	iizz.3.scor	e	\
	0	NaN	0		NaN		0	Na	.N	
	1	NaN	0		NaN		0	Na		
	2	16.0	1		20.0		1	18.	0	
	3	13.0	1		20.0		1	18.	0	
	4	18.0	1		20.0		1	Na	.N	
		Post.forum.4	Post.forum.4.2	2 vie	w.forum.4	view.for	rum.4.2	2 Post.for	um.5	\
	0	0	()	0		()	0	
	1	0	()	0		C)	0	
	2	0	()	1		1	L	0	
	3	0	()	1		()	0	
	4	0	()	0		()	0	
		Post.forum.5.2	view.forum.	5 vie	w.forum.5.	2 last.	/ideo	last.quizz	;	
	0	() ()		0	1	0)	
	1	() ()		0	0	O)	
	2	() :	1		1	34	5	1	
	3	() :	1		0	29	5		
	4	() ()		0	23	2	!	

[5 rows x 73 columns]

```
[]: | # Fusion des tables effec[n] et usage[n] dans des bases intermédiaires selon
     ⇔les identifiants des étudiants
     bases inter = []
     for tabs in [(effec1, usage1), (effec2, usage2), (effec3, usage3)]:
        bases_inter.append(tabs[0].merge(tabs[1], on="Student_ID"))
[]: # Concaténation des tables intermédiaires afin de créer une seule base commune
     base = pd.concat(bases_inter, join="outer",
                      axis=0, ignore_index=False,
                      keys=[1, 2, 3])
[]: base["Certif.bin"].fillna(0, inplace=True)
     base = base.astype({"Exam.bin": bool, "Certif.bin": bool, "Student_ID": int})
[ ]: base = base.copy()
     # Map des modalités M et H de la variable Country HDI
     base["New_HDI"] = np.select([base["Country_HDI"] == "M",
                                  base["Country_HDI"] == "H"],
                                 ["I", "I"], default=base["Country_HDI"])
[]: HDI = base.groupby(["New_HDI"])[["New_HDI"]].count().rename({"New_HDI":__

¬"count"}, axis=1)
[]: HDI
[]:
              count
     New_HDI
    В
               1032
     Ι
                667
     TH
               7264
[]: base = base.reset_index(level=0).rename({"level_0": "Itération"}, axis=1)
[]: # Nombre de catégories (videos, quiz, exam...) par apprenant par place de
     ⇒séquence dans la semaine pour les différentes itérations
     groups = base.groupby(["Student_ID", "Itération"]).sum()
     # Nombre de passages à l'examen
     exam = groups[["Exam.bin"]]
     # Nombre de Certifications
     certif = groups[["Certif.bin"]]
     # Nombre de devoirs par apprenant
     devoir = groups[["Assignment.bin"]]
     # Nombre de videos par apprenant par semaine pour chaque itération
```

```
week_video = [pd.DataFrame(groups.loc[:, 'S1.L1':'S1.L6'].sum(axis=1),__
      ⇔columns=["video.S1"]),
                   pd.DataFrame(groups.loc[:, 'S2.L1': 'S2.L6'].sum(axis=1),__
      ⇔columns=["video.S2"]),
                   pd.DataFrame(groups.loc[:, 'S3.L1.1':'S3.L5'].sum(axis=1), ___
      ⇔columns=["video.S3"]),
                   pd.DataFrame(groups.loc[:, 'S4.L1.1':'S4.L5'].sum(axis=1),__
      ⇔columns=["video.S4"]),
                   pd.DataFrame(groups.loc[:, 'S5.L1.1': 'S5.L5'].sum(axis=1),__
      ⇔columns=["video.S5"])]
     # Nombre de quiz par apprenant par semaine pour chaque itération
     week_quiz = [groups[["Quizz.1.bin"]],
                  groups[["Quizz.2.bin"]],
                  groups[["Quizz.3.bin"]],
                  groups[["Quizz.4.bin"]],
                  groups[["Quizz.5.bin"]]]
[]: # Concaténation des videos et des questionnaires de l'ensemble des semaines
     compil_week_video = pd.concat(week_video, axis=1)
     compil_week_quiz = pd.concat(week_quiz, axis=1)
[]: compil_week_video.head()
[]:
                            video.S1 video.S2 video.S3 video.S4 video.S5
     Student ID Itération
     15
                2
                                   2
                                             0
                                                       0
                                                                  0
                                                                            0
                3
                                             0
                                                       0
                                                                  0
                                                                            0
     28
                1
                                   0
                                             0
                                                       0
                                                                  0
                                                                            0
     34
                3
                                   0
                                             0
                                                       0
                                                                  0
                                                                            0
     36
                1
                                   0
                                             0
                                                       0
                                                                  0
                                                                            0
[]: compil_week_quiz.head()
[]:
                            Quizz.1.bin Quizz.2.bin Quizz.3.bin Quizz.4.bin \
     Student_ID Itération
                                      0
                                                   0
                                                                 0
                                                                              0
     15
                2
                3
                                      0
                                                   0
                                                                 0
                                                                              0
     28
                1
                                      0
                                                   0
                                                                              0
                                                                 0
     34
                3
                                      0
                                                   0
                                                                 0
                                                                              0
     36
                1
                                      0
                                                   0
                                                                              0
                           Quizz.5.bin
     Student_ID Itération
                                      0
     15
                2
                3
                                      0
     28
                1
                                      0
```

```
36
                1
                                      0
[]: # Nombre de videos et questionnaires par itération par apprenant pour_
     \hookrightarrow l'ensemble du MOOC.
     total_video = pd.DataFrame(compil_week_video.sum(axis=1), columns=["video"])
     # Nombre de questionnaires par itération par apprenant pour l'ensemble du MOOC.
     total_quiz = pd.DataFrame(compil_week_quiz.sum(axis=1), columns=["quiz"])
[]: total_video.head()
[]:
                            video
     Student_ID Itération
                                2
     15
                2
                3
                                1
                1
                                0
     28
     34
                3
                                0
     36
                1
[]: total_quiz.head()
[]:
                            quiz
     Student_ID Itération
     15
                2
                               0
                3
                               0
     28
                1
                               0
     34
                3
                               0
     36
                1
                               0
[]: # Création de la table regroupant toutes la variables pour mesurer l'engagement_
      →de chaque apprenant pour chaque itération
     total_student = pd.concat([total_video, total_quiz, devoir, exam, certif],__
      ⇒axis=1)
[]: total_student.head()
[]:
                            video quiz Assignment.bin Exam.bin Certif.bin
     Student_ID Itération
                2
                                2
                                      0
                                                       0
                                                                 0
                                                                              0
     15
                3
                                      0
                                                       0
                                                                 0
                                                                              0
                                1
     28
                1
                                0
                                      0
                                                       0
                                                                 0
                                                                              0
     34
                3
                                0
                                      0
                                                       0
                                                                 0
                                                                              0
     36
                1
                                      0
                                                       0
                                                                 0
                                0
                                                                              0
[]: # Sélection des itérations
     #total_student.xs(1, level=1)
```


```
[]: # selection des types d'apprenant
     def student_type(col):
         video, quiz, devoir, exam, certif = col
         if (exam >= 1 or certif >= 1):
             return "Completer"
         elif quiz > 0 and devoir > 0:
             return "Disengaging"
         elif video > 6:
             return "Auditing"
         else:
             return "Bystander"
[]: total_student["Type"] = total_student.apply(student_type, axis=1)
[]: total_student.head(10)
[]:
                            video quiz Assignment.bin Exam.bin Certif.bin \
     Student_ID Itération
                2
                                2
                                      0
                                                       0
                                                                  0
                                                                              0
     15
                3
                                1
                                       0
                                                       0
                                                                  0
                                                                              0
                                0
     28
                1
                                      0
                                                       0
                                                                  0
                                                                              0
     34
                3
                                0
                                      0
                                                                  0
                                                                              0
     36
                                0
                                      0
                                                       0
                                                                  0
                                                                              0
                1
     45
                1
                               25
                                      5
                                                       0
                                                                  0
                                                                              0
     83
                1
                               22
                                      5
                                                       1
                                                                  0
                                                                              0
     84
                1
                                8
                                      2
                                                       0
                                                                  0
                                                                              0
     87
                1
                                       0
                                                       0
                                                                  0
                                                                              0
                                1
                3
                                      0
                                                       0
                                                                  0
                                                                              0
     88
                                1
                                   Type
    Student_ID Itération
     15
                2
                              Bystander
                3
                              Bystander
     28
                1
                              Bystander
     34
                3
                              Bystander
     36
                1
                              Bystander
     45
                1
                               Auditing
     83
                1
                            Disengaging
     84
                1
                               Auditing
     87
                1
                              Bystander
                3
     88
                              Bystander
[]: student = total_student.reset_index()[["Student_ID", "Type", "Itération"]]
[]: student["Type"].value_counts()
```

```
[]: Bystander
                    8691
    Disengaging
                    2643
                    2120
     Auditing
     Completer
                    1728
     Name: Type, dtype: int64
[]: # Calcul du nombre d'apprenants par type et par itération
     df_type = student.groupby(["Itération", "Type"])[["Type"]].count().


¬rename({'Type': 'total'}, axis=1)
[]: df_type
[]:
                            total
     Itération Type
                             1207
               Auditing
               Bystander
                             4285
               Completer
                               20
               Disengaging
                             2453
     2
               Auditing
                              538
               Bystander
                             2168
               Completer
                              876
               Disengaging
                              120
     3
               Auditing
                              375
               Bystander
                             2238
               Completer
                              832
               Disengaging
                               70
[]: df_type.reset_index("Type", inplace=True)
[]: # Nombre total d'apprenants par itération
     df_iter = df_type.groupby("Itération").sum()
[]: df iter
[]:
                total
     Itération
                 7965
     1
     2
                 3702
     3
                 3515
[]: total_iter = df_type.merge(df_iter, on="Itération", suffixes=["_type", "_iter"])
[]: total_iter
[]:
                       Type total_type total_iter
     Itération
                   Auditing
                                   1207
                                                7965
     1
                                               7965
     1
                  Bystander
                                   4285
```

```
1
                  Completer
                                      20
                                                 7965
                                                 7965
     1
                Disengaging
                                    2453
     2
                   Auditing
                                     538
                                                 3702
     2
                  Bystander
                                    2168
                                                 3702
     2
                  Completer
                                     876
                                                 3702
     2
                Disengaging
                                     120
                                                 3702
     3
                   Auditing
                                     375
                                                 3515
     3
                  Bystander
                                    2238
                                                 3515
     3
                  Completer
                                     832
                                                 3515
     3
                                      70
                Disengaging
                                                 3515
[]: # Proportion d'apprenants par types d'apprenants et par itération
     total_iter["proportion/iter"] = round(total_iter["total_type"] /__
      ⇔total_iter["total_iter"] * 100, 1)
[]: total_iter
[]:
                             total_type total_iter proportion/iter
     Itération
     1
                   Auditing
                                    1207
                                                 7965
                                                                   15.2
     1
                  Bystander
                                    4285
                                                 7965
                                                                   53.8
                  Completer
                                                                    0.3
     1
                                      20
                                                 7965
     1
                Disengaging
                                    2453
                                                 7965
                                                                   30.8
     2
                   Auditing
                                     538
                                                 3702
                                                                   14.5
     2
                  Bystander
                                                                   58.6
                                    2168
                                                 3702
     2
                                                                   23.7
                  Completer
                                     876
                                                 3702
     2
                                                                    3.2
                Disengaging
                                     120
                                                 3702
                                                                   10.7
     3
                   Auditing
                                     375
                                                 3515
     3
                  Bystander
                                    2238
                                                 3515
                                                                   63.7
                  Completer
     3
                                     832
                                                 3515
                                                                   23.7
     3
                Disengaging
                                      70
                                                 3515
                                                                    2.0
[]: base["Genre"] = base["Gender"].map({"un homme": "Homme", "une femme": "Femme"})
[]: # Tableau de contingence (croisement des 2 variables catégorielles)
     tab_obs = pd.crosstab(index=base["Genre"], columns=base["New_HDI"])
[]: tab_obs.rename(columns={"un homme": "H", "une femme": "F"}, inplace=True)
[ ]: tab_obs
[]: New_HDI
                      Ι
                           TH
                В
     Genre
     Femme
              147
                   233
                         2545
     Homme
              883
                   432
                        4711
[]: #tab obs = tab HDI qender.melt(value_vars=["H", "F"], var_name="qenre", __
      →value_name="residus", ignore_index=False).reset_index()
```

```
[ ]: #tab_obs
[]: # Test d'indépendance (chi2)
     chi2, p_value, degres_liberte, tableau_attendu = chi2_contingency(tab_obs)
[]: tableau_attendu
[]: array([[ 336.58250475,
                             217.308122 , 2371.10937325],
            [ 693.41749525, 447.691878 , 4884.89062675]])
[]: chi2
[]: 179.2420322171424
[]: p_value
[]: 1.196980957821505e-39
    La p value est < 5% indiquerait que l'index HDI serait significativement lié au genre puisqu'il y a
    moins de 5 \% de chance que les 2 variables soient indépendantes.
[]: | #residus = (tab_HDI_gender - tableau_attendu) / tableau_attendu
     residus = tab_obs - tableau_attendu
[]: residus
[]: New_HDI
                       В
                                   Т
                                              TH
     Genre
     Femme
             -189.582505 15.691878 173.890627
     Homme
              189.582505 -15.691878 -173.890627
[]: # Mosaic du tableau de contingence
     #props = lambda key: {'color': 'red' if residus(key[0]) > 0 else 'blue'},
     fig, ax = plt.subplots(figsize=(8,5))
     mosaic(tab_obs.stack(), statistic=True, gap=0.02, horizontal=False, ax=ax)
     ax.set_xlabel("HDI")
     ax.set_ylabel("Genre")
     plt.savefig("../graph/mosaic_contingence.png")
     plt.show()
```



```
[]: # valeurs attendues sous l'hypothèse nulle (HO).
    x = tableau_attendu.flatten()
[]: x
[]: array([ 336.58250475, 217.308122 , 2371.10937325, 693.41749525,
            447.691878 , 4884.89062675])
[]: # valeurs observées
    y = tab_obs.stack().values
[ ]: y
[]: array([147, 233, 2545, 883, 432, 4711])
[]: # Résidus du modèle de prédiction
    fig, ax = plt.subplots()
    sns.residplot(x=x, y=y, ax=ax)
    #ax.set_title("Résidus du modèle observé")
    ax.set_ylabel("Résidu")
    ax.set_xlabel("Valeur prédite")
    plt.savefig("../graph/residus_chi2.png")
    plt.show()
```



fig, ax = plt.subplots() sns.heatmap(residus, annot=True, cmap='coolwarm', cbar=True, ax=ax) ax.set_ylabel("Genre") ax.set_ylabel("HDI") plt.show()

formule du V de Cramer :

$$V = \sqrt{(2 / (n * (min(r, c) - 1)))}$$

Dans cette formule:

V représente le coefficient de Cramer. ² est la statistique du chi carré. n est la taille de l'échantillon. r est le nombre de niveaux ou de catégories de la première variable. c est le nombre de niveaux ou de catégories de la deuxième variable.

```
[]: # Fonction de calcul du V de Cramer

# data = tab ndarray

def V_Cramer(data):
    # somme de chaque colonne
    n = np.sum(data)
    # taille du tableau de contingence des variables catégorielles (taille de⊔
    →chaque échantillon pour chaque variable)
    row, col = tab_obs.shape
    # Formule du V de Cramer
    V = np.sqrt(chi2 / (n * (min([row, col]) - 1)))
    return V
```

```
[]: V_Cramer(np.array(tab_obs))
```

```
[]: 0.14150902903141144
    V_Cramer(tableau_attendu)
[]: 0.14150902903141144
    La valeur V de Cramer étant faible il y a aurait une faible dépendance entre l'index HDI et le genre.
    Il y aurait donc statistiquement une association entre ses deux variables catégorielles, indiquée par
    la p-value du chi2, mais la valeur du V de Cramer indiquerait que cette dépendance serait faible.
[]: # tableau du genre par étudiant
     genre_etu = base[["Student_ID", "Genre"]].drop_duplicates(subset="Student_ID").
      →dropna()
[]: genre_etu.head()
[]:
        Student_ID
                     Genre
             19178
                     Femme
     1
     2
               1086
                     Femme
     3
               1948 Femme
     4
              16209
                     Femme
     5
               6685
                     Homme
[]: # Nombre total de videos par étudiant
     total_video_etu = total_video.groupby("Student_ID").sum()
[]: total_video_etu.head()
[]:
                  video
     Student_ID
     15
                      3
     28
                      0
     34
                      0
     36
                      0
     45
                     25
[]: # tableau du genre et du nombre total de videos visionnées par étudiant
     etu_genre_video = total_video_etu.merge(genre_etu, on='Student_ID')
[]:
     etu_genre_video.head()
[]:
        Student_ID
                            Genre
                     video
     0
                 45
                        25
                            Femme
     1
                 83
                        22
                            Homme
                         8
                            Homme
     2
                 84
     3
                 87
                            Homme
```

4

94

2

Homme

```
[]: # moyenne du nombre de videos visionnées par genre total_video_etu.merge(genre_etu, on="Student_ID").groupby("Genre")[["video"]].


→mean()
```

[]: video
Genre
Femme 14.855376

13.867276

Homme

```
[]: # Figure de la distribution du nombre de video par rapport au genre
fig, ax = plt.subplots()
sns.barplot(data=etu_genre_video, x="Genre", y="video", ax=ax)
ax.set_xlabel("Genre")
ax.set_ylabel("Nombre moyen de Videos")
plt.savefig("../graph/mean_video.png")
plt.show()
```



H0 (Hypothèse nulle) : il n'y a pas de différence sur le nombre de video visionnées entre les hommes et les femmes

```
[]: tab_stat = etu_genre_video.pivot_table(columns="Genre", index="Student_ID", ovalues="video").fillna(0)
```

[]: tab_stat.head()

```
[]: Genre
                  Femme
                          Homme
     Student_ID
     45
                    25.0
                             0.0
     83
                     0.0
                            22.0
     84
                             8.0
                     0.0
     87
                     0.0
                             1.0
     94
                     0.0
                             2.0
```

```
[]: # Test de Student
statistique, p_value = t_student(tab_stat["Homme"], tab_stat["Femme"])
```

```
[]: statistique
```

[]: 26.98492395204523

```
[]: p_value
```

[]: 3.4121378553908065e-157

Il y a moins de 5% de chance qu'il n'y ait pas de différence du nombre de visionnages entre les femmes et les hommes. Il y aurait significativement un lien entre le nombre de visionnages et le genre.

```
[]: # Sélection par genre

df_hom = etu_genre_video[etu_genre_video["Genre"] == "Homme"]


df_fem = etu_genre_video[etu_genre_video["Genre"] == "Femme"]
```

[]: df_hom


```
[]:
            Student_ID
                         video
                                 Genre
     1
                            22
                                 Homme
                     83
     2
                     84
                             8
                                Homme
     3
                     87
                              1
                                 Homme
     4
                             2
                                Homme
                     94
     5
                     98
                            23
                                 Homme
     8807
                 68205
                            30
                                 Homme
     8808
                 68220
                             30
                                 Homme
     8809
                 68223
                             0
                                Homme
     8811
                 68265
                             14
                                 Homme
     8813
                 68282
                                 Homme
                              1
```

[5907 rows x 3 columns]

```
[]: # Calcul des paramètres de la distribution normale pour chaque groupe
mu_hommes, std_hommes = np.mean(df_hom["video"]), np.std(df_hom["video"])
mu_femmes, std_femmes = np.mean(df_fem["video"]), np.std(df_fem["video"])
```



[]: # visualisation de la normalité de la distribution des données (histogramme de distribution)



La distribution des données ne suit pas une loi normale. Ce qui ne permet pas de faire un test t-Student puisque la condition première est que les données doivent être normalement distribuées.

```
[]: # Models de regression du nombre de video selon le genre
    mdl_video_vs_genre = ols("video ~ Genre", data=etu_genre_video).fit()

[]: mdl_video_vs_genre.summary()

[]: <class 'statsmodels.iolib.summary.Summary'>
```

OLS Regression Results

Dep. Variable:		video	R-squared:		0.002				
Model:		OLS	Adj. R-squ	ared:	0.001				
Method:	Lea	ast Squares	F-statisti	c:	13.45				
		5 Jun 2023	Prob (F-st	atistic):	0.000247				
Time:		15:25:02 Log-Likelihood:		-34348.					
No. Observations:		8818	AIC:		6.870e+04				
Df Residuals:		8816	BIC:		6.871e+04				
Df Model:		1							
Covariance Type:		nonrobust							
=======================================	.=======	.=======		========					
==									
	coef	std err	t	P> t	[0.025				
0.975]									
Intercept	14.8554	0.221	67.365	0.000	14.423				
15.288									
Genre[T.Homme]	-0.9881	0.269	-3.667	0.000	-1.516				
-0.460									
===========		.=======		========	=========				
Omnibus:		59307.238	Durbin-Watson:		1.962				
<pre>Prob(Omnibus):</pre>		0.000	Jarque-Ber	a (JB):	878.417				
Skew:		0.240	•		1.80e-191				
Kurtosis:		1.530	Cond. No.		3.24				
===========		.=======			=========				

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.


Le coefficient R² étant proche de 0, le model de régression est peu fidèle à l'observation des données.

[]: mdl_video_vs_genre.params


[]: Intercept 14.855376 Genre[T.Homme] -0.988100

dtype: float64

[]: # Test de normalité de la distribution des données (Q-Q plot)
qqplot(data=mdl_video_vs_genre.resid, fit=True, line="45")
plt.show()




```
[]: qqplot(data=data, fit=True, line="45")
  plt.xlabel("Quantiles théoriques")
  plt.ylabel("Quantiles observés ")
  plt.savefig("../graph/distribution_video3.png")
  plt.show()
```



```
[]: # Test de Kolmogrov-Smirnov
    stat, p = kstest(data, 'norm')
[]: stat, p
[]: (0.7626887430801719, 0.0)
[]: # Test non paramétrique de Mann-Whitney U
    mannwhitneyu(df_hom["video"], df_fem["video"])
[]: MannwhitneyuResult(statistic=8200580.5, pvalue=0.0003907509304995919)
[]: # Nombre de quiz par étudiant
    total_quiz_etu = total_quiz.groupby("Student_ID").sum()
[]: # Nombre de Quiz et vidéos par étudiants
    video_quiz_etu = total_video_etu.merge(total_quiz_etu, on="Student_ID")
[]: video_quiz_etu.loc[3139]
[]: video
             48
    quiz
             10
    Name: 3139, dtype: int64
[]: data = pd.concat([video_quiz_etu["quiz"], video_quiz_etu["video"]])
```

```
[]: qqplot(data=data, fit=True, line="45")
  plt.xlabel("Quantiles théoriques")
  plt.ylabel("Quantiles observés ")
  plt.savefig("../graph/distribution_video4.png")
  plt.show()
```



[]: (0.804511796629543, 0.0)

Il y a une forte corrélation (0.8) entre le nombre de videos vues et le nombre de quiz réalisés par un étudiant. La corrélation observée est statistiquement significative (p-value=0).

```
[]: # Modèle de regression sur le nombre de vidéos selon le nombre de quiz mdl_video_vs_quiz = ols("quiz ~ video", data=video_quiz_etu).fit()
```

[]: mdl_video_vs_quiz.summary()

[]: <class 'statsmodels.iolib.summary.Summary'>

OLS Regression Results

______ Dep. Variable: quiz R-squared: 0.646 Model: OLS Adj. R-squared: 0.646 Method: Least Squares F-statistic: 2.653e+04 Date: Thu, 15 Jun 2023 Prob (F-statistic): 0.00 15:25:03 Log-Likelihood: -24981.Time: No. Observations: 14557 AIC: 4.997e+04 Df Residuals: 14555 BIC: 4.998e+04


Df Model: 1
Covariance Type: nonrobust


______ coef std err t P>|t| Γ0.025 ______ Intercept 0.5652 0.014 39.183 0.000 0.537 0.594 0.000 video 0.1575 0.001 162.896 0.156 0.159 ______ Omnibus: 5315.454 Durbin-Watson: 1.939 Prob(Omnibus): 0.000 Jarque-Bera (JB): 20116.783 Skew: 1.821 Prob(JB): 0.00 Kurtosis: 7.461 Cond. No. 19.3

Notes:


[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

```
[]: intercept, coef = mdl_video_vs_quiz.params
    sns.scatterplot(data=video_quiz_etu, x="video", y="quiz")
    plt.axline(xy1=(0,intercept), slope=coef, color="red")
    plt.savefig("../graph/scatter_regression.png")
    plt.show()
```





```
[]: # Résidus du modèle de prédiction
fig, ax = plt.subplots()
sns.residplot(data=video_quiz_etu, x="video", y="quiz", ax=ax)
#ax.set_title("Résidus du modèle observé")
ax.set_ylabel("Résidu")
ax.set_xlabel("Valeur prédite")
plt.savefig("../graph/residus_regression.png")
plt.show()
```



```
[]: # HDI des apprenants
     student_hdi = base[["Student_ID", "New_HDI"]].dropna().set_index("Student_ID")
     student_hdi.sort_values("Student_ID", inplace=True)
[]: student_hdi
[]:
                New_HDI
     Student_ID
     45
                     TH
     83
                      Ι
     84
                      В
    87
                     TH
    94
                     ΤH
     68282
                      В
     68326
                     TΗ
     68332
                      Ι
     68365
                     TH
     69565
                     TH
     [8963 rows x 1 columns]
[]: # Tableau des 3 variables dont 2 catégorielles et 1 continue
```

video_genre_hdi = etu_genre_video.merge(student_hdi, on="Student_ID")

[]: video_genre_hdi []: Student_ID video Genre New_HDI 0 45 25 Femme 22 Homme Ι 1 83 2 8 Homme В 84 1 Homme 3 87 TH 2 Homme 4 94 TH 8860 68282 1 Homme В 8861 68326 30 Femme TH 8862 68332 4 Femme Ι 8863 68365 0 Femme ΤH 8864 69565 9 Femme TH [8865 rows x 4 columns] []: # Modèle linéaire sans interaction(genre, HDI, video) mdl1 = ols("video ~ C(Genre) + C(New HDI)", data=video genre_hdi).fit() []: mdl1.summary() []: <class 'statsmodels.iolib.summary.Summary'> OLS Regression Results Dep. Variable: video R-squared: 0.057 Adj. R-squared: Model: OLS 0.056 Method: Least Squares F-statistic: 177.2 Date: Thu, 15 Jun 2023 Prob (F-statistic): 1.41e-111 15:25:04 Log-Likelihood: Time: -34351. No. Observations: 6.871e+04 8865 AIC: BIC: Df Residuals: 8861 6.874e+04 Df Model: Covariance Type: nonrobust coef std err t P>|t| [0.025 0.975Intercept 7.0011 0.432 16.211 0.000 6.155 7.848 C(Genre) [T.Homme] -0.0959 0.267 -0.360 0.719 -0.618 0.427 C(New_HDI)[T.I] 4.6774 0.586 7.979 0.000 3.528 5.826

	C(New_HDI)[T.TH] 9.448	8.6728	0.395	21.9	37 0.00	00 7	7.898
	Omnibus: Prob(Omnibus): Skew: Kurtosis:	0	.000	Durbin-W Jarque-B Prob(JB) Cond. No	era (JB): :		1.891 639.581 1.31e-139 8.79
	Notes: [1] Standard Errors specified.	assume that t	he cova	ariance m	atrix of the	e errors i	s correctly
[]:	# ANOVA sans interdanova_table = sm.st		dl1, ty	vp=1)			
[]:	anova_table						
[]:	df C(Genre) 1.0 C(New_HDI) 2.0 Residual 8861.0	7.071483e+04	1554. 35357.		F 11.437356 260.078874 NaN	7.229351	
[]:	# Modèle de regress mdl2 = ols("video ~			', data=v	ideo_genre_	hdi).fit()	
[]:	mdl2.summary()						
[]:	<class 'statsmodels<="" td=""><td>.iolib.summary</td><td>.Summar</td><td>·y'></td><td></td><td></td><td></td></class>	.iolib.summary	.Summar	·y'>			
			_	on Resul	ts 		
	Dep. Variable: Model: Method: Date: Time: No. Observations: Df Residuals: Df Model: Covariance Type:	v Least Squ Thu, 15 Jun 15:2 nonro	ideo OLS ares 2023 5:04 8865 8859 5 bust	Log-Like AIC: BIC:	quared: tic: statistic): lihood:		0.057 0.057 107.8 7.64e-111 -34347. 6.871e+04 6.875e+04
	[0.025 0.975]	·		coef	std err	t 	P> t

Intercept			7.3310	0.968	7.573	0.000
5.434 9.229						
C(Genre)[T.Homme]			-0.4810	1.046	-0.460	0.646
-2.531 1.569						
C(New_HDI)[T.I]			2.7733	1.236	2.244	0.025
0.350 5.196						
C(New_HDI)[T.TH]			8.4673	0.995	8.506	0.000
6.516 10.419	N IIDT)	[m ተ]	0.0000	4 445	1 000	0.040
C(Genre)[T.Homme]:C(0.030 5.576	NeM_HDI)	[1.1]	2.8032	1.415	1.982	0.048
C(Genre)[T.Homme]:C(New HDT)	רד דעו	0.1933	1.085	0.178	0.859
-1.933 2.320	Mem_HDT)	[1.111]	0.1933	1.005	0.176	0.009
=======================================	=======		=======	.======		.=======
Omnibus:	-	11724.976	Durbin-W	latson:		1.891
Prob(Omnibus):		0.000	Jarque-E	Bera (JB)	:	637.561
Skew:		0.217	Prob(JB)	:		3.59e-139
~~ ** •						33.0
Kurtosis: Notes: [1] Standard Errors specified.						
Kurtosis: Notes: [1] Standard Errors specified.	assume th					
Kurtosis: Notes: [1] Standard Errors specified.	assume th	nat the co	variance m			
Kurtosis: Notes: [1] Standard Errors specified. """ # ANOVA avec interact	assume th	nat the co	variance m			
Kurtosis: Notes: [1] Standard Errors specified. """ # ANOVA avec interac anova_table = sm.sta	assume th	at the co	variance m	matrix of		
Kurtosis: Notes: [1] Standard Errors specified. """ # ANOVA avec interac anova_table = sm.sta	assume the tion tion ts.anova	at the co	variance m	mean_sq	the errors	is correct
Kurtosis: Notes: [1] Standard Errors specified. """ # ANOVA avec interac anova_table = sm.sta anova_table	assume the tion ts.anova	at the co lm(mdl2, sum 1.554895e	typ=1) _sq +03 1554	mean_sq	the errors	is correct
Kurtosis: Notes: [1] Standard Errors specified. """ # ANOVA avec interact anova_table = sm.sta anova_table C(Genre)	assume the tion ts.anova.	lm(mdl2, sum 1.554895e 7.071483e	typ=1) sq +03 1554	mean_sq 1.895102	the errors F 11.443839	is correct
Kurtosis: Notes: [1] Standard Errors specified. """ # ANOVA avec interact anova_table = sm.sta anova_table C(Genre) C(New_HDI)	assume the tion ts.anova df 1.0 2.0 2.0	lm(mdl2, sum 1.554895e 7.071483e	typ=1) sq +03 1554 +04 35357	mean_sq 1.895102	the errors F 11.443839 260.226287	is correct
Kurtosis: Notes: [1] Standard Errors specified. """ # ANOVA avec interact anova_table = sm.sta anova_table C(Genre) C(New_HDI) C(Genre):C(New_HDI)	df 1.0 2.0 2.0 8859.0	sum 1.554895e 7.071483e 9.541531e 1.203688e	typ=1) sq +03 1554 +04 35357	mean_sq 1.895102 7.416782	the errors F 11.443839 260.226287 3.511225	is correct
Kurtosis: ==================================	assume the strong tto anovariate the strong df 1.0 2.0 2.0 8859.0	lm(mdl2, sum 1.554895e 7.071483e 9.541531e 1.203688e PR(>F)	typ=1) sq +03 1554 +04 35357	mean_sq 1.895102 7.416782	the errors F 11.443839 260.226287 3.511225	is correct
Kurtosis:	df 1.0 2.0 2.0 8859.0	sum 1.554895e 7.071483e 9.541531e 1.203688e PR(>F)	typ=1) sq +03 1554 +04 35357	mean_sq 1.895102 7.416782	the errors F 11.443839 260.226287 3.511225	is correct
Kurtosis: ==================================	df 1.0 2.0 2.0 8859.0	sum 1.554895e 7.071483e 9.541531e 1.203688e PR(>F) 12e-04 3e-110	typ=1) sq +03 1554 +04 35357	mean_sq 1.895102 7.416782	the errors F 11.443839 260.226287 3.511225	is correct
Kurtosis:	df 1.0 2.0 2.0 8859.0	sum 1.554895e 7.071483e 9.541531e 1.203688e PR(>F) 12e-04 3e-110	typ=1) sq +03 1554 +04 35357	mean_sq 1.895102 7.416782	the errors F 11.443839 260.226287 3.511225	is correct

[]

[]

[]

⊶et l'HDI

df_exam = base.groupby(["Student_ID", "Itération", "Gender", "New_HDI"])[["Exam.

[]: # obtention de l'examen /certification par étudiant par session, selon le genreu

obin", "Certif.bin"]].sum().reset_index(["Gender", "New_HDI"])

```
[]: df_exam.rename(columns={"Exam.bin": "Exam", "Certif.bin": "Certif"},__
      →inplace=True)
[]: df_exam
[]:
                            Gender New_HDI Exam Certif
    Student_ID Itération
    45
               1
                                        TH
                                               0
                                                       0
                          une femme
    83
                                         Ι
                                               0
                                                       0
               1
                          un homme
    84
               1
                           un homme
                                         В
                                               0
                                                       0
    87
               1
                          un homme
                                        TH
                                               0
    94
               1
                          un homme
    68282
               3
                          un homme
                                         В
                                               0
                                                       0
    68326
               3
                          une femme
                                                       0
                                        TH
                                               1
               3
                                         Ι
                                               1
                                                       1
    68332
                          une femme
               3
                                                       0
    68365
                          une femme
                                        TH
                                               0
    69565
               3
                          une femme
                                                       0
                                        TH
                                               0
    [8951 rows x 4 columns]
[]: # Obtention de l'examen et/ou de la certification
    df_exam["Exam_Certif"] = df_exam["Exam"] | df_exam["Certif"]
[]: # Generalized Linear Models (Formula)
    formula = "Exam_Certif ~ Gender + New_HDI"
[]: # Modèle logistic de type binomial (variable dépendante binaire)
    model = glm(formula=formula, data=df_exam, family=sm.families.Binomial())
[]: result = model.fit()
[]: odds_ratios = np.exp(result.params)
[]: odds_ratios
[]: Intercept
                           0.166282
    Gender[T.une femme]
                           1.121606
    New_HDI[T.I]
                           1.118971
    New_HDI[T.TH]
                           1.372423
    dtype: float64
[]: result.summary()
[]: <class 'statsmodels.iolib.summary.Summary'>
    11 11 11
                     Generalized Linear Model Regression Results
    ______
```

Dep. Variable: Model: Model Family: Link Function: Method: Date: Time: No. Iterations:	Thu, 15 Jun 15:2	GLM omial Logit IRLS 2023 25:19	Df Df Sca Log Dev Pea	-Likelihoo	1:	8951 8947 3 1.0000 -4269.0 8538.0 8.95e+03 0.002283	
Covariance Type:	nonro	obust					
0.975]	coef	std e	==== rr 	z	P> z	[0.025	
 Intercept -1.620	-1.7941	0.0	89	-20.151	0.000	-1.969	
<pre>Gender[T.une femme] 0.228</pre>	0.1148	0.0	58	1.984	0.047	0.001	
New_HDI[T.I] 0.383	0.1124	0.1	38	0.814	0.416	-0.158	
New_HDI[T.TH] 0.501	0.3166	0.0	94	3.358	0.001	0.132	

======

11 11 11