mooc mertes

June 24, 2023

```
[4959]: import pandas as pd
       import numpy as np
       import matplotlib.pyplot as plt
       import seaborn as sns
       import statsmodels.api as sm
       import forestplot as fp
       import missingno as msno
       from statsmodels.graphics.mosaicplot import mosaic
       from statsmodels.formula.api import ols
       from statsmodels.formula.api import logit
       from statsmodels.formula.api import glm
       from statsmodels.api import qqplot
       from scipy.stats import ttest_ind as t_student
       from scipy.stats import mannwhitneyu
       from scipy.stats import chi2_contingency
       from scipy.stats import pearsonr
       from scipy.stats import spearmanr
       from scipy.stats import kstest
       from scipy.stats import norm
       from matplotlib.patches import Rectangle
[4960]: # Chargement des données
       effec1 = pd.read_csv("../csv/effec1.quest.compil.csv", encoding="ISO-8859-1")
       effec2 = pd.read csv("../csv/effec2.quest.compil.csv", encoding="ISO-8859-1")
       effec3 = pd.read_csv("../csv/effec3.quest.compil.csv", encoding="ISO-8859-1")
       usage1 = pd.read_csv("../csv/usages.effec1.csv", encoding="ISO-8859-1")
       usage2 = pd.read_csv("../csv/usages.effec2.csv", encoding="ISO-8859-1")
       usage3 = pd.read_csv("../csv/usages.effec3.csv", encoding="ISO-8859-1")
[4961]: effec3.info()
       <class 'pandas.core.frame.DataFrame'>
       RangeIndex: 4233 entries, 0 to 4232
       Data columns (total 26 columns):
       #
           Column
                            Non-Null Count Dtype
       --- ----
                             _____
        0
           Student ID
                            3883 non-null
                                             float64
```

```
2
            Section
                              1587 non-null
                                               object
        3
            Gender
                              1577 non-null
                                               object
        4
            birth.year
                              1543 non-null
                                              float64
        5
            Country
                              1575 non-null
                                               object
        6
            Diploma
                              1574 non-null
                                              object
            EMLYON.et
        7
                              1567 non-null
                                               object
        8
            Formation
                              1562 non-null
                                               object
            CSP
                              1572 non-null
                                              object
        10 How.heard
                              1571 non-null
                                              object
        11 Exp.crea
                              1570 non-null
                                               object
        12 Curiosity.MOOC
                              1569 non-null
                                               object
        13 Certif.self.sat
                              1561 non-null
                                              float64
                                               object
        14 Rencontres
                              1551 non-null
        15 Certif.work
                                              float64
                              1562 non-null
        16 Incitation
                              1564 non-null
                                              float64
        17
           Temps.Dispo
                              1561 non-null
                                              object
        18 Exp.MOOC
                              1556 non-null
                                              object
            Completion.proba 1559 non-null
                                              float64
        20 EMLyon
                              1567 non-null
                                              object
        21
            Country HDI
                              1562 non-null
                                               object
        22
            Country_HDI.fin
                              1562 non-null
                                               object
        23
            age
                              1543 non-null
                                              float64
        24
            CSP.fin
                              1572 non-null
                                              object
        25 Temps.dispo.fin
                              1561 non-null
                                              object
       dtypes: float64(8), object(18)
       memory usage: 860.0+ KB
[4962]: # Fusion des tables effec[n] et usage[n] dans des bases intermédiaires selonu
        ⇔les identifiants des étudiants
       bases_inter = []
       for tabs in [(effec1, usage1), (effec2, usage2), (effec3, usage3)]:
            bases_inter.append(tabs[0].merge(tabs[1], on="Student_ID"))
[4963]: # Concaténation des tables intermédiaires afin de créer une seule base commune
       base = pd.concat(bases_inter, join="outer",
                         axis=0, ignore_index=False,
                         keys=[1, 2, 3])
[4964]: # Indication de non passage de la certification pour les itération 1 et 2 où
         \Rightarrowseul l'examen existe.
       base["Certif.bin"].fillna(0, inplace=True)
[4965]: base = base.astype({"Exam.bin": bool, "Certif.bin": bool, "Student_ID": int})
[4966]: base = base.copy()
        # Map des modalités M et H de la variable Country_HDI
```

Certif.bin

1

3883 non-null

float64

```
base["Country_HDI"] == "H"],
                                    ["I", "I"], default=base["Country_HDI"])
[4967]: base = base.reset_index(level=0).rename({"level_0": "Itération"}, axis=1)
[4968]: # Nombre de catégories (videos, quiz, exam...) par apprenant par place de la
        séquence dans la semaine pour les différentes itérations
        groups = base.groupby(["Student_ID", "Itération"]).sum()
        # Nombre de passages à l'examen
        exam = groups[["Exam.bin"]]
        # Nombre de Certifications
        certif = groups[["Certif.bin"]]
        # Nombre de devoirs par apprenant
        devoir = groups[["Assignment.bin"]]
        # Nombre de videos par apprenant par semaine pour chaque itération
        week_video = [pd.DataFrame(groups.loc[:, 'S1.L1': 'S1.L6'].sum(axis=1),_
         ⇔columns=["video.S1"]),
                      pd.DataFrame(groups.loc[:, 'S2.L1':'S2.L6'].sum(axis=1),_
         ⇔columns=["video.S2"]),
                      pd.DataFrame(groups.loc[:, 'S3.L1.1': 'S3.L5'].sum(axis=1),___
         ⇔columns=["video.S3"]),
                      pd.DataFrame(groups.loc[:, 'S4.L1.1': 'S4.L5'].sum(axis=1),__
         ⇔columns=["video.S4"]),
                      pd.DataFrame(groups.loc[:, 'S5.L1.1':'S5.L5'].sum(axis=1),__
         ⇔columns=["video.S5"])]
        # Nombre de quiz par apprenant par semaine pour chaque itération
        week_quiz = [groups[["Quizz.1.bin"]],
                     groups[["Quizz.2.bin"]],
                     groups[["Quizz.3.bin"]],
                     groups[["Quizz.4.bin"]],
                     groups[["Quizz.5.bin"]]]
[4969]: # Concaténation des videos et des questionnaires de l'ensemble des semaines
        compil week video = pd.concat(week video, axis=1)
        compil_week_quiz = pd.concat(week_quiz, axis=1)
[4970]: compil_week_video.head()
[4970]:
                              video.S1 video.S2 video.S3 video.S4 video.S5
        Student_ID Itération
        15
                   2
                                     2
                                               0
                                                         0
                                                                   0
                                                                              0
```

base["New_HDI"] = np.select([base["Country_HDI"] == "M",

```
28
                    1
                                       0
                                                  0
                                                             0
                                                                        0
                                                                                   0
        34
                    3
                                       0
                                                  0
                                                             0
                                                                        0
                                                                                   0
                                                  0
                                                             0
        36
                    1
                                       0
                                                                                   0
[4971]: compil_week_quiz.head()
[4971]:
                                Quizz.1.bin Quizz.2.bin Quizz.3.bin Quizz.4.bin \
        Student_ID Itération
                                           0
                                                         0
        15
                                                                       0
                                                                                     0
                    3
                                           0
                                                         0
                                                                       0
                                                                                     0
        28
                    1
                                           0
                                                         0
                                                                       0
                                                                                     0
        34
                    3
                                           0
                                                         0
                                                                       0
                                                                                     0
        36
                    1
                                           0
                                                         0
                                                                       0
                                                                                     0
                                Quizz.5.bin
        Student_ID Itération
        15
                    2
                                           0
                    3
                                           0
        28
                    1
                                           0
        34
                    3
                                           0
                    1
                                           0
        36
[4972]: # Nombre de videos et questionnaires par itération par apprenant pour
         \hookrightarrowl'ensemble du MOOC.
        total_video = pd.DataFrame(compil_week_video.sum(axis=1), columns=["video"])
        # Nombre de questionnaires par itération par apprenant pour l'ensemble du MOOC.
        total_quiz = pd.DataFrame(compil_week_quiz.sum(axis=1), columns=["quiz"])
[4973]: total_video.head()
[4973]:
                                video
        Student_ID Itération
                                    2
        15
                    2
                    3
                                    1
        28
                    1
                                    0
                    3
                                    0
        34
                    1
                                    0
        36
[4974]: total_quiz.head()
[4974]:
                                quiz
        Student_ID Itération
        15
                    2
                                   0
                    3
                                   0
        28
                    1
                                   0
```

```
34
                   3
                                  0
        36
                   1
                                  0
[4975]: # Création de la table regroupant toutes la variables pour mesurer l'engagement
        →de chaque apprenant pour chaque itération
        total_student = pd.concat([total_video, total_quiz, devoir, exam, certif],__
         ⇔axis=1)
[4976]: total_student.head()
[4976]:
                               video quiz Assignment.bin Exam.bin Certif.bin
        Student_ID Itération
                   2
                                   2
                                         0
                                                          0
                                                                    0
                                                                                 0
        15
                   3
                                   1
                                         0
                                                          0
                                                                    0
                                                                                 0
        28
                                   0
                                         0
                                                          0
                                                                                 0
                   1
                                                                    0
                   3
                                   0
                                         0
                                                          0
                                                                    0
                                                                                 0
        34
                   1
                                                          0
                                                                                 0
        36
                                         0
                                                                    0
[4977]: # Sélection des itérations
        #total_student.xs(1, level=1)
[4978]: # selection des types d'apprenant
        def student_type(col):
            video, quiz, devoir, exam, certif = col
            if (exam >= 1 or certif >= 1):
                return "Completer"
            elif quiz > 0 and devoir > 0:
                return "Disengaging"
            elif video > 6:
                return "Auditing"
            else:
                return "Bystander"
[4979]: total_student["Type"] = total_student.apply(student_type, axis=1)
[4980]: total_student.head(10)
[4980]:
                               video quiz Assignment.bin Exam.bin Certif.bin \
        Student_ID Itération
                   2
                                   2
                                         0
                                                          0
                                                                    0
                                                                                 0
        15
                                         0
                                                                    0
                                                                                 0
                   3
                                   1
                                                          0
        28
                   1
                                   0
                                         0
                                                          0
                                                                    0
                                                                                 0
        34
                   3
                                   0
                                         0
                                                          0
                                                                    0
                                                                                 0
                                   0
                                         0
                                                          0
        36
                   1
                                                                    0
                                                                                 0
        45
                   1
                                  25
                                         5
                                                          0
                                                                    0
                                                                                 0
                                  22
                                         5
        83
                   1
                                                          1
                                                                    0
                                                                                 0
        84
                   1
                                   8
                                         2
```

```
88
                   3
                                         0
                                                          0
                                                                    0
                                                                                 0
                                      Туре
        Student_ID Itération
        15
                   2
                                 Bystander
                   3
                                 Bystander
        28
                   1
                                 Bystander
        34
                   3
                                 Bystander
        36
                   1
                                 Bystander
        45
                   1
                                  Auditing
        83
                   1
                               Disengaging
        84
                   1
                                  Auditing
        87
                   1
                                 Bystander
        88
                   3
                                 Bystander
       student = total_student.reset_index()[["Student_ID", "Type", "Itération"]]
[4981]:
[4982]: student["Type"].value_counts()
[4982]: Bystander
                        8691
        Disengaging
                        2643
        Auditing
                        2120
        Completer
                       1728
        Name: Type, dtype: int64
[4983]: # Calcul du nombre d'apprenants par type et par itération
        df_type = student.groupby(["Itération", "Type"])[["Type"]].count().
         →rename({'Type': 'total'}, axis=1)
[4984]: df_type
[4984]:
                                total
        Itération Type
        1
                  Auditing
                                 1207
                                 4285
                  Bystander
                  Completer
                                   20
                  Disengaging
                                 2453
        2
                  Auditing
                                  538
                  Bystander
                                 2168
                  Completer
                                  876
                  Disengaging
                                  120
        3
                  Auditing
                                  375
                  Bystander
                                 2238
                  Completer
                                  832
                  Disengaging
                                   70
```

87

1

1

0


0

0


0

```
[4985]: df_type.reset_index("Type", inplace=True)
[4986]: # Nombre total d'apprenants par itération
        df_iter = df_type.groupby("Itération").sum()
[4987]: df iter
[4987]:
                   total
        Itération
        1
                    7965
        2
                     3702
        3
                    3515
[4988]: total_iter = df_type.merge(df_iter, on="Itération", suffixes=["_type", "_iter"])
[4989]: total_iter
[4989]:
                           Type total_type total_iter
        Itération
        1
                       Auditing
                                       1207
                                                    7965
        1
                     Bystander
                                       4285
                                                    7965
        1
                      Completer
                                          20
                                                    7965
                   Disengaging
        1
                                       2453
                                                    7965
        2
                       Auditing
                                        538
                                                    3702
        2
                     Bystander
                                       2168
                                                    3702
        2
                     Completer
                                        876
                                                    3702
        2
                                        120
                                                    3702
                   Disengaging
        3
                       Auditing
                                        375
                                                    3515
        3
                      Bystander
                                       2238
                                                    3515
        3
                      Completer
                                                    3515
                                        832
        3
                   Disengaging
                                          70
                                                    3515
[4990]: # Proportion d'apprenants par types d'apprenants et par itération
        total_iter["proportion/iter"] = round(total_iter["total_type"] /_
         ⇔total_iter["total_iter"] * 100, 1)
[4991]: total_iter
[4991]:
                           Type total_type total_iter proportion/iter
        Itération
        1
                       Auditing
                                       1207
                                                    7965
                                                                      15.2
        1
                     Bystander
                                       4285
                                                    7965
                                                                      53.8
        1
                      Completer
                                          20
                                                    7965
                                                                       0.3
        1
                   Disengaging
                                       2453
                                                    7965
                                                                      30.8
        2
                       Auditing
                                        538
                                                    3702
                                                                      14.5
        2
                      Bystander
                                       2168
                                                    3702
                                                                      58.6
                      Completer
                                                                      23.7
        2
                                        876
                                                    3702
                   Disengaging
                                        120
                                                    3702
                                                                       3.2
```

```
3
                       Auditing
                                        375
                                                    3515
                                                                      10.7
        3
                     Bystander
                                                    3515
                                                                      63.7
                                       2238
                     Completer
        3
                                        832
                                                    3515
                                                                      23.7
        3
                   Disengaging
                                                                       2.0
                                         70
                                                    3515
[4992]: base["Genre"] = base["Gender"].map({"un homme": "Homme", "une femme": "Femme"})
[4993]: # Tableau de contingence (croisement des 2 variables catégorielles)
        tab_obs = pd.crosstab(index=base["Genre"], columns=base["New_HDI"])
[4994]:
       tab_obs.rename(columns={"un homme": "H", "une femme": "F"}, inplace=True)
[4995]: tab_obs
[4995]: New HDI
                   В
                         Ι
                              TH
        Genre
        Femme
                 147
                      233
                            2545
        Homme
                 883
                      432
                            4711
[4996]: # Test d'indépendance (chi2)
        chi2, p_value, degres_liberte, tableau_attendu = chi2_contingency(tab_obs)
[4997]: tableau attendu
[4997]: array([[ 336.58250475,
                                 217.308122 , 2371.10937325],
               [ 693.41749525,
                                 447.691878
                                             , 4884.89062675]])
[4998]: chi2
[4998]: 179.2420322171424
[4999]: p_value
[4999]: 1.196980957821505e-39
       La p value est < 5\% indiquerait que l'index HDI serait significativement lié au genre puisqu'il y a
       moins de 5 % de chance que les 2 variables soient indépendantes.
[5000]: #residus = (tab HDI_qender - tableau_attendu) / tableau_attendu
        residus = tab_obs - tableau_attendu
[5001]: residus
[5001]: New HDI
                           В
                                      Ι
                                                  TH
        Genre
        Femme
                -189.582505 15.691878 173.890627
                 189.582505 -15.691878 -173.890627
        Homme
```



```
[5007]: # Résidus du modèle de prédiction
fig, ax = plt.subplots()
sns.residplot(x=x, y=y, ax=ax)
#ax.set_title("Résidus du modèle observé")
ax.set_ylabel("Résidu")
ax.set_xlabel("Valeur prédite")
plt.savefig("../graph/residus_chi2.png")
plt.show()
```



fig, ax = plt.subplots() sns.heatmap(residus, annot=True, cmap='coolwarm', cbar=True, ax=ax) ax.set_ylabel("Genre") ax.set_ylabel("HDI") plt.show()

formule du V de Cramer :

$$V = \sqrt{(\ ^2\ /\ (n\ ^*\ (min(r,\,c)\ \text{-}\ 1)))}$$


Dans cette formule:

V représente le coefficient de Cramer. $\,^2$ est la statistique du chi carré. n est la taille de l'échantillon. r est le nombre de niveaux ou de catégories de la première variable. c est le nombre de niveaux ou de catégories de la deuxième variable.

```
# taille du tableau de contingence des variables catégorielles (taille de l
          ⇔chaque échantillon pour chaque variable)
            row, col = tab_obs.shape
            # Formule du V de Cramer
            V = np.sqrt(chi2 / (n * (min([row, col]) - 1)))
            return V
[5009]: V_Cramer(np.array(tab_obs))
[5009]: 0.14150902903141144
[5010]: V_Cramer(tableau_attendu)
[5010]: 0.14150902903141144
       La valeur V de Cramer étant faible il y a aurait une faible dépendance entre l'index HDI et le genre.
       Il y aurait donc statistiquement une association entre ses deux variables catégorielles, indiquée par
       la p-value du chi2, mais la valeur du V de Cramer indiquerait que cette dépendance serait faible.
[5011]: # tableau du genre par étudiant
        genre_etu = base[["Student_ID", "Genre"]].drop_duplicates(subset="Student_ID").
          ⊶dropna()
[5012]: genre_etu.head()
[5012]:
           Student_ID
                        Genre
        1
                19178
                        Femme
        2
                  1086 Femme
        3
                  1948 Femme
        4
                 16209 Femme
        5
                  6685 Homme
[5013]: # Nombre total de videos par étudiant
        total_video_etu = total_video.groupby("Student_ID").sum()
[5014]: total_video_etu.head()
[5014]:
                     video
        Student_ID
                         3
        15
        28
                         0
        34
                         0
        36
                         0
        45
                        25
[5015]: # tableau du genre et du nombre total de videos visionnées par étudiant
        etu_genre_video = total_video_etu.merge(genre_etu, on='Student_ID')
```

```
[5016]: etu_genre_video.head()
[5016]:
           Student_ID
                       video
                              Genre
                   45
                          25
                              Femme
                   83
                          22 Homme
        1
        2
                   84
                           8
                             Homme
        3
                   87
                              Homme
                           1
        4
                              Homme
                   94
[5017]: # moyenne du nombre de videos visionnées par genre
        total_video_etu.merge(genre_etu, on="Student_ID").groupby("Genre")[["video"]].
         →mean()
[5017]:
                   video
        Genre
        Femme
               14.855376
        Homme
               13.867276
[5018]: # Figure de la distribution du nombre de video par rapport au genre
        fig, ax = plt.subplots()
        sns.barplot(data=etu_genre_video, x="Genre", y="video", ax=ax)
        ax.set_xlabel("Genre")
        ax.set_ylabel("Nombre moyen de Videos")
        plt.savefig("../graph/mean_video.png")
```

plt.show()





H0 (Hypothèse nulle) : il n'y a pas de différence sur le nombre de video visionnées entre les hommes et les femmes

```
[5019]: tab_stat = etu_genre_video.pivot_table(columns="Genre", index="Student_ID", __
          ⇔values="video").fillna(0)
[5020]: tab_stat.head()
[5020]: Genre
                     Femme
                            Homme
        Student_ID
        45
                      25.0
                               0.0
        83
                       0.0
                              22.0
        84
                       0.0
                               8.0
        87
                       0.0
                               1.0
        94
                       0.0
                               2.0
[5021]: # Test de Student
        statistique, p_value = t_student(tab_stat["Homme"], tab_stat["Femme"])
[5022]:
       statistique
[5022]: 26.98492395204523
[5023]: p_value
[5023]: 3.4121378553908065e-157
       Il y a moins de 5% de chance qu'il n'y ait pas de différence du nombre de visionnages entre les
       femmes et les hommes. Il y aurait significativement un lien entre le nombre de visionnages et le
       genre.
[5024]: # Sélection par genre
        df hom = etu genre video[etu genre video["Genre"] == "Homme"]
        df_fem = etu_genre_video[etu_genre_video["Genre"] == "Femme"]
[5025]:
        df_hom
[5025]:
               Student_ID
                                   Genre
                           video
                       83
                               22
                                   Homme
        1
        2
                       84
                                8
                                   Homme
        3
                       87
                                   Homme
        4
                       94
                                2
                                   Homme
        5
                       98
                               23
                                  Homme
        8807
                    68205
                               30 Homme
        8088
                    68220
                               30 Homme
                                   Homme
        8809
                    68223
                                0
                                   Homme
        8811
                    68265
        8813
                    68282
                                   Homme
```

[5907 rows x 3 columns]

```
[5026]: # Calcul des paramètres de la distribution normale pour chaque groupe
        mu_hommes, std_hommes = np.mean(df_hom["video"]), np.std(df_hom["video"])
        mu_femmes, std_femmes = np.mean(df_fem["video"]), np.std(df_fem["video"])
        # Création des valeurs x pour tracer la courbe théorique
        x_hommes = np.linspace(min(df_hom["video"]), max(df_hom["video"]), 100)
        x_femmes = np.linspace(min(df_fem["video"]), max(df_fem["video"]), 100)
        # Calcul des valeurs y correspondantes en utilisant la PDF de la distribution
         \rightarrownormale
        y_hommes = norm.pdf(x_hommes, mu_hommes, std_hommes)
        y_femmes = norm.pdf(x_femmes, mu_femmes, std_femmes)
[5027]: figure, ax1 = plt.subplots()
        sns.histplot(data=df hom, x="video", bins=10, color="tab:blue", ax=ax1,__
        ا"H") ⇔label
        sns.histplot(data=df_fem, x="video", bins=10, color="pink", ax=ax1, label="F")
        ax1.set_xlabel("video")
        ax1.set ylabel("Nombre d'étudiants")
        ax1.legend(title="Genre")
        ax2 = ax1.twinx()
        ax2.plot(x_hommes, y_hommes, color='blue')
        ax2.plot(x_femmes, y_femmes, color='pink')
        plt.savefig("../graph/distribution_video.png")
        plt.show()
```





La distribution des données ne suit pas une loi normale. Ce qui ne permet pas de faire un test t-Student puisque la condition première est que les données doivent être normalement distribuées.

```
[5029]: # Models de regression du nombre de video selon le genre
       mdl_video_vs_genre = ols("video ~ Genre", data=etu_genre_video).fit()
      mdl_video_vs_genre.summary()
[5030]:
[5030]: <class 'statsmodels.iolib.summary.Summary'>
                                 OLS Regression Results
       ______
       Dep. Variable:
                                                                           0.002
                                     video
                                            R-squared:
       Model:
                                      OLS
                                            Adj. R-squared:
                                                                           0.001
                                          F-statistic:
       Method:
                             Least Squares
                                                                           13.45
       Date:
                          Fri, 23 Jun 2023
                                            Prob (F-statistic):
                                                                        0.000247
                                  20:00:50
                                            Log-Likelihood:
                                                                         -34348.
       Time:
       No. Observations:
                                            AIC:
                                                                       6.870e+04
                                     8818
       Df Residuals:
                                            BIC:
                                     8816
                                                                       6.871e+04
       Df Model:
                                        1
       Covariance Type:
                                 nonrobust
                          coef
                                  std err
                                                  t
                                                        P>|t|
                                                                  Γ0.025
       0.975]
```

Intercept 15.288	14.8554	0.221	67.365	0.000	14.423
<pre>Genre[T.Homme]</pre>	-0.9881	0.269	-3.667	0.000	-1.516
-0.460					
Omnibus:		59307.238	Durbin-Wat	son:	1.962
Prob(Omnibus):		0.000	Jarque-Ber	a (JB):	878.417
Skew:		0.240	Prob(JB):		1.80e-191
Kurtosis:		1.530	Cond. No.		3.24

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified. $\footnote{1}{1}$


Le coefficient R² étant proche de 0, le model de régression est peu fidèle à l'observation des données.

```
[5031]: mdl_video_vs_genre.params
```


[5031]: Intercept 14.855376 Genre[T.Homme] -0.988100

dtype: float64

```
[5032]: # Test de normalité de la distribution des données (Q-Q plot)
qqplot(data=mdl_video_vs_genre.resid, fit=True, line="45")
plt.show()
```




```
[5033]: qqplot(data=data, fit=True, line="45")
    plt.xlabel("Quantiles théoriques")
    plt.ylabel("Quantiles observés ")
    plt.savefig("../graph/distribution_video3.png")
    plt.show()
```



```
stat, p = kstest(data, 'norm')
[5035]: stat, p
[5035]: (0.7626887430801719, 0.0)
[5036]: # Test non paramétrique de Mann-Whitney U
        mannwhitneyu(df_hom["video"], df_fem["video"])
[5036]: MannwhitneyuResult(statistic=8200580.5, pvalue=0.0003907509304995919)
[5037]: # Nombre de quiz par étudiant
        total_quiz_etu = total_quiz.groupby("Student_ID").sum()
[5038]: # Nombre de Quiz et vidéos par étudiants
        video_quiz_etu = total_video_etu.merge(total_quiz_etu, on="Student_ID")
[5039]: video_quiz_etu.loc[3139]
[5039]: video
                 48
        quiz
                 10
        Name: 3139, dtype: int64
[5040]: data = pd.concat([video_quiz_etu["quiz"], video_quiz_etu["video"]])
```

[5034]: # Test de Kolmogrov-Smirnov

```
[5041]: qqplot(data=data, fit=True, line="45")
    plt.xlabel("Quantiles théoriques")
    plt.ylabel("Quantiles observés ")
    plt.savefig("../graph/distribution_video4.png")
    plt.show()
```



Il y a une forte corrélation (0.8) entre le nombre de videos vues et le nombre de quiz réalisés par un étudiant. La corrélation observée est statistiquement significative (p-value=0).

```
[5046]: # Modèle de regression sur le nombre de vidéos selon le nombre de quiz mdl_video_vs_quiz = ols("quiz ~ video", data=video_quiz_etu).fit()
```

[5047]: mdl_video_vs_quiz.summary()

[5047]: <class 'statsmodels.iolib.summary.Summary'>

OLS Regression Results

______ Dep. Variable: quiz R-squared: 0.646 Model: OLS Adj. R-squared: 0.646 Method: Least Squares F-statistic: 2.653e+04 Date: Fri, 23 Jun 2023 Prob (F-statistic): 0.00 20:00:51 Log-Likelihood: -24981.Time: No. Observations: 14557 AIC: 4.997e+04 Df Residuals: 14555 BIC: 4.998e+04


Df Model: 1
Covariance Type: nonrobust


______ P>|t| coef std err t Γ0.025 ______ Intercept 0.5652 0.014 39.183 0.000 0.537 0.594 0.001 0.000 video 0.1575 162.896 0.156 0.159 _____ Omnibus: 5315.454 Durbin-Watson: 1.939 Jarque-Bera (JB): Prob(Omnibus): 0.000 20116.783 Skew: 1.821 Prob(JB): 0.00 Kurtosis: 7.461 Cond. No. 19.3 ______

Notes


[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

```
[5048]: intercept, coef = mdl_video_vs_quiz.params
    sns.scatterplot(data=video_quiz_etu, x="video", y="quiz")
    plt.axline(xy1=(0,intercept), slope=coef, color="red")
    plt.savefig("../graph/scatter2_regression.png")
    plt.show()
```





```
[5050]: # Résidus du modèle de prédiction
fig, ax = plt.subplots()
sns.residplot(data=video_quiz_etu, x="video", y="quiz", ax=ax)
#ax.set_title("Résidus du modèle observé")
ax.set_ylabel("Résidu")
ax.set_xlabel("Valeur prédite")
plt.savefig("../graph/residus_regression.png")
plt.show()
```



```
[5051]: # HDI des apprenants
        student_hdi = base[["Student_ID", "New_HDI"]].dropna().set_index("Student_ID")
        student_hdi.sort_values("Student_ID", inplace=True)
[5052]:
       student_hdi
[5052]:
                   New_HDI
        Student_ID
        45
                        TH
        83
                         Ι
        84
                         В
        87
                        ΤH
        94
                        ΤH
        68282
                         В
        68326
                        TΗ
        68332
                         Ι
        68365
                        ΤH
        69565
                        TH
        [8963 rows x 1 columns]
[5053]: # Tableau des 3 variables dont 2 catégorielles et 1 continue
        video_genre_hdi = etu_genre_video.merge(student_hdi, on="Student_ID")
```

```
[5054]: video_genre_hdi
[5054]:
             Student_ID video Genre New_HDI
       0
                     45
                            25 Femme
                            22 Homme
                                            Ι
       1
                     83
       2
                             8 Homme
                                            В
                     84
                             1 Homme
       3
                     87
                                           TH
                             2 Homme
       4
                     94
                                           TH
       8860
                  68282
                             1 Homme
                                            В
       8861
                  68326
                            30 Femme
                                            TH
       8862
                  68332
                             4 Femme
                                            Ι
       8863
                  68365
                             0 Femme
                                            ΤH
       8864
                  69565
                             9 Femme
                                            TH
       [8865 rows x 4 columns]
[5055]: # Modèle linéaire sans interaction(genre, HDI, video)
       mdl1 = ols("video ~ C(Genre) + C(New HDI)", data=video genre_hdi).fit()
[5056]: mdl1.summary()
[5056]: <class 'statsmodels.iolib.summary.Summary'>
                                   OLS Regression Results
       Dep. Variable:
                                       video
                                               R-squared:
                                                                                0.057
                                               Adj. R-squared:
       Model:
                                         OLS
                                                                                0.056
       Method:
                               Least Squares
                                               F-statistic:
                                                                                177.2
       Date:
                            Fri, 23 Jun 2023 Prob (F-statistic):
                                                                            1.41e-111
                                    20:00:52 Log-Likelihood:
       Time:
                                                                              -34351.
       No. Observations:
                                                                            6.871e+04
                                        8865
                                               AIC:
                                               BIC:
       Df Residuals:
                                        8861
                                                                            6.874e+04
       Df Model:
       Covariance Type:
                                   nonrobust
       =====
                               coef
                                       std err
                                                        t
                                                               P>|t|
                                                                           [0.025
       0.975
       Intercept
                             7.0011
                                        0.432
                                                   16.211
                                                              0.000
                                                                           6.155
       7.848
       C(Genre) [T.Homme]
                            -0.0959
                                         0.267
                                                   -0.360
                                                               0.719
                                                                          -0.618
       0.427
       C(New_HDI)[T.I]
                             4.6774
                                         0.586
                                                    7.979
                                                               0.000
                                                                           3.528
       5.826
```

	C(New_HDI)[T.TH] 9.448	8.6728 0.3	95 21.937	0.000	7.898
	Omnibus: Prob(Omnibus): Skew: Kurtosis:	1.759	Jarque-Bera (Prob(JB):		1.891 639.581 1.31e-139 8.79
	Notes: [1] Standard Errors specified. """	s assume that the c	ovariance matrix	of the err	ors is correctly
[5057]:	# ANOVA sans inter anova_table = sm.s		typ=1)		
[5058]:	anova_table				
[5058]:	-	7.071483e+04 353		F 137356 7.2 078874 1.73 NaN	
[5059]:	<pre># Modèle de regres mdl2 = ols("video en en</pre>			_genre_hdi).	fit()
[5060]:	mdl2.summary()				
[5060]:	<pre><class """<="" 'statsmodels="" pre=""></class></pre>	s.iolib.summary.Sum	mary'>		
		•	ssion Results		
	Dep. Variable: Model: Method: Date: Time: No. Observations: Df Residuals: Df Model: Covariance Type:	video OLS Least Squares Fri, 23 Jun 2023 20:00:52 8865 8859 5	R-squared: Adj. R-square F-statistic: Prob (F-stati Log-Likelihoo AIC: BIC:	istic):	0.057 0.057 107.8 7.64e-111 -34347. 6.871e+04 6.875e+04
	[0.025 0.975]		coef std	err	t P> t

	Intercept		7.3310	0.968	7.573	0.000
	5.434 9.229 C(Genre)[T.Homme]		-0.4810	1.046	-0.460	0.646
	-2.531 1.569		0.7700	1 000	0.044	0.005
	C(New_HDI)[T.I] 0.350 5.196		2.7733	1.236	2.244	0.025
	C(New_HDI)[T.TH]		8.4673	0.995	8.506	0.000
	6.516 10.419 C(Genre) [T.Homme]:C(New_HDI)[T.I]	2.8032	1.415	1.982	0.048
	0.030 5.576 C(Genre)[T.Homme]:C(New_HDI)[T.TH]	0.1933	1.085	0.178	0.859
	-1.933 2.320					
	Omnibus:	11724.976	Durbin-W			1.891
	Prob(Omnibus):	0.000	-	era (JB):		637.561
	Skew: Kurtosis:	0.217 1.760	Prob(JB) Cond. No			3.59e-139 33.0
	=======================================	============				=======
[5061]:	# ANOVA avec interac	tion				
5-0007	anova_table = sm.sta	ts.anova_lm(mdl2,	typ=1)			
[5062]:		ts.anova_lm(mdl2,	typ=1)			
[5062]:	anova_table		n_sq e+03 1554 e+04 35357 e+02 477	mean_sq .895102 .416782 .076535 .871810	F 11.443839 260.226287 3.511225 NaN	\
	anova_table C(Genre) C(New_HDI) C(Genre):C(New_HDI)	df sur 1.0 1.5548956 2.0 7.0714836 2.0 9.5415316	n_sq e+03 1554 e+04 35357 e+02 477	.895102 .416782 .076535	11.443839 260.226287 3.511225	\
	anova_table C(Genre) C(New_HDI) C(Genre):C(New_HDI) Residual	df sur 1.0 1.5548956 2.0 7.0714836 2.0 9.5415316 8859.0 1.2036886 PR(>F) 7.204212e-04	n_sq e+03 1554 e+04 35357 e+02 477	.895102 .416782 .076535	11.443839 260.226287 3.511225	\
	anova_table C(Genre) C(New_HDI) C(Genre):C(New_HDI) Residual C(Genre) C(New_HDI)	df sur 1.0 1.5548956 2.0 7.0714836 2.0 9.5415316 8859.0 1.2036886 PR(>F) 7.204212e-04 1.514733e-110	n_sq e+03 1554 e+04 35357 e+02 477	.895102 .416782 .076535	11.443839 260.226287 3.511225	\
	anova_table C(Genre) C(New_HDI) C(Genre):C(New_HDI) Residual	df sur 1.0 1.5548956 2.0 7.0714836 2.0 9.5415316 8859.0 1.2036886 PR(>F) 7.204212e-04	n_sq e+03 1554 e+04 35357 e+02 477	.895102 .416782 .076535	11.443839 260.226287 3.511225	\
	anova_table C(Genre) C(New_HDI) C(Genre):C(New_HDI) Residual C(Genre) C(New_HDI) C(Genre):C(New_HDI) Residual	df sur 1.0 1.5548956 2.0 7.0714836 2.0 9.5415316 8859.0 1.2036886 PR(>F) 7.204212e-04 1.514733e-110 2.990187e-02 NaN	n_sq e+03 1554 e+04 35357 e+02 477 e+06 135	.895102 .416782 .076535 .871810	11.443839 260.226287 3.511225 NaN	

```
[5064]: df_exam.rename(columns={"Exam.bin": "Exam", "Certif.bin": "Certif"}, __
          →inplace=True)
[5065]: df_exam
[5065]:
                                  Gender New_HDI Exam Certif
        Student_ID Itération
                               une femme
        45
                   1
                                               TH
                                                      0
                                                              0
        83
                                               Ι
                                                      0
                                                              0
                   1
                                un homme
                                                              0
        84
                   1
                                un homme
                                               В
                                                      0
        87
                   1
                                un homme
                                               TH
                                                      0
                                                              0
        94
                   1
                                un homme
                                                      0
        68282
                   3
                                un homme
                                               В
                                                      0
                                                              0
        68326
                   3
                               une femme
                                               TH
                                                              0
                                                      1
        68332
                   3
                               une femme
                                               Ι
                                                      1
                                                              1
                   3
                                                              0
        68365
                               une femme
                                               TH
                                                      0
        69565
                   3
                               une femme
                                                      0
                                                              0
                                               TH
        [8951 rows x 4 columns]
[5066]: # Obtention de l'examen et/ou de la certification
        df_exam["Exam_Certif"] = df_exam["Exam"] | df_exam["Certif"]
[5067]: # Obtention ou non par itération
        df_exam_v1 = df_exam.xs(1, level="Itération")
        df_exam_v2 = df_exam.xs(2, level="Itération")
        df_exam_v3 = df_exam.xs(3, level="Itération")
[5068]: df exam v3["Exam Certif"].unique()
[5068]: array([1, 0])
[5069]: # Generalized Linear Models (Formula du GLM)
        formula = "Exam_Certif ~ Gender + New_HDI"
[5070]: # Modèle logistic (GLM) de type binomial (variable dépendante binaire)
        model = \lceil \rceil
        for n, version in enumerate([df_exam_v1, df_exam_v2, df_exam_v3]):
            model.append(glm(formula=formula, data=version, family=sm.families.
         →Binomial()))
[5071]: # résultats de la fonction logistic par itération
        result_v1 = model[0].fit()
        result v2 = model[1].fit()
        result_v3 = model[2].fit()
[5072]: result_v1.summary()
```

[5072]: <class 'statsmodels.iolib.summary.Summary'>

Generalized Linear Model Regression Results

Dep. Variable:	Exam_Certif		No. Observation	5237	
Model:	GLM		Df Residuals:		523
Model Family:	Binomial Logit IRLS Fri, 23 Jun 2023 20:00:52		Df Model:	1.0000 -128.64 257.28 4.84e+03 0.001021	
Link Function:			Scale:		
Method:			Log-Likelihood:		
Date:			Deviance:		
Time:			Pearson chi2:		
No. Iterations:	25		Pseudo R-squ. (
Covariance Type:	nonr	obust			
=======================================	========	======		======	========
======	c	. 1		D. I. I	FO 005
0.975]	coef	std ei	r z	P> z	[0.025
0.975]					
Intercept	-5.9120	0.73	L5 -8.266	0.000	-7.314
-4.510					
<pre>Gender[T.une femme]</pre>	0.6235	0.45	1.367	0.172	-0.270
1.517					
New_HDI[T.I]	-20.8950	1.75e+0	04 -0.001	0.999	-3.43e+04
3.42e+04					
New_HDI[T.TH]	0.2241	0.75	0.297	0.767	-1.257
1.705					
				=======	
======					
II II II					
F 11 77 4 11 11 11 11 11 11 11 11 11 11 11 11 1	"TTO !!]				
mooc = ["V1", "V2",	"٧3"]				
# Calcul des odds-ro	1 : 3	, .	7		

```
[5074]: # Calcul des odds-ratio, p-value et ci pour chaque itération
full_odds_r, full_pvalues, full_ci = [], [], []
for n, version in enumerate([result_v1, result_v2, result_v3]):
    # OR
    odds = np.exp(version.params).round(3)
    odds_r = odds / odds["Intercept"]
    odds_r.name = mooc[n]
    full_odds_r.append(odds_r)
    # p-value
    p_values = version.pvalues.round(3)
    p_values.name = mooc[n]
```

ci = version.conf_int(alpha=0.05) # intervalle à 95 %


full_pvalues.append(p_values)
interval de confiance (ci)


```
sup = np.exp(ci[1]) / np.exp(ci.loc["Intercept", 0])
                           inf = np.exp(ci[0]) / np.exp(ci.loc["Intercept", 1])
                           ci = "[" + inf.round(3).astype(str) + ", " + sup.round(3).astype(str) + "]"
                           ci.name = mooc[n]
                           full_ci.append(ci)
[5075]: tab_coef = pd.concat([pd.DataFrame(full_odds_r).T, pd.DataFrame(full_pvalues).
                     →T, pd.DataFrame(full ci).T])
[5076]: tab coef
[5076]:
                                                                                                        V1
                                                                                                                                             ٧2
                                                                                                                                                                                  VЗ
                  Intercept
                                                                                                      1.0
                                                                                                                                           1.0
                                                                                                                                                                                1.0
                  Gender[T.une femme]
                                                                                                                                                                    0.641167
                                                                                     621.666667
                                                                                                                                 2.32574
                  New HDI[T.I]
                                                                                                      0.0
                                                                                                                               2.382688
                                                                                                                                                                    0.837539
                  New HDI[T.TH]
                                                                                                                               3.548975
                                                                                                                                                                    0.658517
                                                                                                 417.0
                  Intercept
                                                                                                      0.0
                                                                                                                                           0.0
                                                                                                                                                                           0.157
                  Gender[T.une femme]
                                                                                                 0.172
                                                                                                                                      0.826
                                                                                                                                                                           0.053
                  New HDI[T.I]
                                                                                                 0.999
                                                                                                                                      0.849
                                                                                                                                                                           0.813
                  New_HDI[T.TH]
                                                                                                 0.767
                                                                                                                                      0.004
                                                                                                                                                                           0.311
                  Intercept
                                                                          [0.061, 16.503]
                                                                                                                 [0.561, 1.783]
                                                                                                                                                      [0.518, 1.931]
                  Gender[T.une femme]
                                                                   [69.397, 6844.388]
                                                                                                                  [1.451, 3.721]
                                                                                                                                                      [0.374, 1.099]
                  New HDI[T.I]
                                                                                      [0.0, inf]
                                                                                                                 [1.125, 5.04]
                                                                                                                                                      [0.367, 1.907]
                  New_HDI[T.TH]
                                                                   [25.872, 8259.698]
                                                                                                                 [1.959, 6.424]
                                                                                                                                                      [0.334, 1.297]
[5077]: index = pd.MultiIndex.from_arrays([["odds-ratio", "odds-ratio", 
                     ⇔"odds-ratio",
                                                                                                      "p-value", "p-value", "p-value",
                                                                                                      "ci", "ci", "ci", "ci"],
                                                                                                      tab_coef.index], names=["type", "coef"])
[5078]: tab_full = pd.DataFrame({"V1": list(tab_coef["V1"]), "V2":__
                     ⇔list(tab_coef["V2"]), "V3": list(tab_coef["V3"])}, index=index)
[5079]: tab_full.reset_index(inplace=True)
[5080]: tab_full.set_index(["type"], inplace=True)
[5081]: tab_full
[5081]:
                                                                                 coef
                                                                                                                                   V1
                                                                                                                                                                         V2 \
                  type
                  odds-ratio
                                                                     Intercept
                                                                                                                                  1.0
                                                                                                                                                                       1.0
                  odds-ratio Gender[T.une femme]
                                                                                                                 621.666667
                                                                                                                                                             2.32574
                  odds-ratio
                                                              New HDI[T.I]
                                                                                                                                  0.0
                                                                                                                                                           2.382688
                  odds-ratio
                                                           New HDI[T.TH]
                                                                                                                                                           3.548975
                                                                                                                             417.0
                  p-value
                                                                     Intercept
                                                                                                                                  0.0
                                                                                                                                                                      0.0
```


```
p-value
                    Gender[T.une femme]
                                                        0.172
                                                                        0.826
        p-value
                           New_HDI[T.I]
                                                                        0.849
                                                        0.999
        p-value
                          New_HDI[T.TH]
                                                        0.767
                                                                        0.004
                                                               [0.561, 1.783]
                                             [0.061, 16.503]
        ci
                               Intercept
                    Gender[T.une femme]
                                          [69.397, 6844.388]
                                                              [1.451, 3.721]
        сi
                           New_HDI[T.I]
                                                  [0.0, inf]
                                                                [1.125, 5.04]
        ci
                          New_HDI[T.TH]
                                          [25.872, 8259.698]
                                                               [1.959, 6.424]
        ci
                                 VЗ
        type
        odds-ratio
                                1.0
        odds-ratio
                          0.641167
        odds-ratio
                          0.837539
        odds-ratio
                          0.658517
        p-value
                              0.157
        p-value
                              0.053
        p-value
                              0.813
        p-value
                              0.311
                    [0.518, 1.931]
        сi
                    [0.374, 1.099]
        сi
                    [0.367, 1.907]
        ci
                    [0.334, 1.297]
        ci
       p > 0.05: Non significatif (pas d'astérisque) 0.01 : * (un astérisque) <math>0.001 :
       ** (deux astérisques) p 0.001 : *** (trois astérisques)
[5082]: ci v1 = tab full.loc["ci", ["coef", "V1"]]
        or_v1 = tab_full.loc["odds-ratio", ["coef", "V1"]]
        pval_v1 = tab_full.loc["p-value", ["coef", "V1"]]
        ci_v2 = tab_full.loc["ci", ["coef", "V2"]]
        or v2 = tab full.loc["odds-ratio", ["coef", "V2"]]
        pval v2 = tab full.loc["p-value", ["coef", "V2"]]
        ci_v3 = tab_full.loc["ci", ["coef", "V3"]]
        or_v3 = tab_full.loc["odds-ratio", ["coef", "V3"]]
        pval_v3 = tab_full.loc["p-value", ["coef", "V3"]]
[5083]: ci_v1.rename(columns={'V1': 'CI'}, inplace=True)
        ci_v2.rename(columns={'V2': 'CI'}, inplace=True)
        ci_v3.rename(columns={'V3': 'CI'}, inplace=True)
        or_v1.rename(columns={'V1': 'OR'}, inplace=True)
        or_v2.rename(columns={'V2': 'OR'}, inplace=True)
        or_v3.rename(columns={'V3': 'OR'}, inplace=True)
        pval_v1.rename(columns={'V1': 'pval'}, inplace=True)
        pval_v2.rename(columns={'V2': 'pval'}, inplace=True)
```

```
pval_v3.rename(columns={'V3': 'pval'}, inplace=True)
[5084]: # Extraction des bornes inférieure et supérieure des CI
        ci_v1[["ll", "hl"]] = ci_v1["CI"].str.strip("[]").str.split(",", expand=True).
         ⇔astype(float)
        ci_v2[["11", "h1"]] = ci_v2["CI"].str.strip("[]").str.split(",", expand=True).
         →astype(float)
        ci_v3[["ll", "hl"]] = ci_v3["CI"].str.strip("[]").str.split(",", expand=True).
         ⇔astype(float)
[5085]: # Tableaux des valeurs pour créer le forestplot
        forest_v1 = ci_v1.merge(or_v1, on="coef").merge(pval_v1, on="coef")
        forest_v2 = ci_v2.merge(or_v2, on="coef").merge(pval_v2, on="coef")
        forest_v3 = ci_v3.merge(or_v3, on="coef").merge(pval_v3, on="coef")
[5086]: # Renommage de l'intercept
        forest_v1.iloc[0, 0] = "Réf (homme/HDI B)"
        forest_v2.iloc[0, 0] = "Réf (homme/HDI B)"
        forest_v3.iloc[0, 0] = "Réf (homme/HDI B)"
[5087]: # Mise à zero des intervalle de confiance de l'intercept
        forest_v1.loc[0, "11"] = 0
        forest_v1.loc[0, "hl"] = 0
        forest v2.loc[0, "11"] = 0
        forest v2.loc[0, "hl"] = 0
        forest v3.loc[0, "11"] = 0
        forest_v3.loc[0, "hl"] = 0
[5088]: forest_v1
[5088]:
                                                                               OR \
                          coef
                                                CI
                                                        11
                                                                  hl
             Réf (homme/HDI B)
                                   [0.061, 16.503]
        0
                                                     0.000
                                                               0.000
                                                                              1.0
          Gender[T.une femme]
                                [69.397, 6844.388]
                                                    69.397
                                                            6844.388 621.666667
                                        [0.0, inf]
        2
                  New HDI[T.I]
                                                     0.000
                                                                  inf
                                                                              0.0
        3
                 New_HDI[T.TH]
                                [25.872, 8259.698]
                                                    25.872 8259.698
                                                                            417.0
           pval
            0.0
        0
        1 0.172
        2 0.999
        3 0.767
[5089]: forest v2
[5089]:
                                                   11
                          coef
                                            CI
                                                          hl
                                                                    OR
                                                                          pval
                                [0.561, 1.783] 0.000 0.000
             Réf (homme/HDI B)
                                                                    1.0
                                                                           0.0
          Gender[T.une femme]
                                [1.451, 3.721] 1.451
                                                                        0.826
                                                       3.721
                                                               2.32574
```

```
2
                 New_HDI[T.I]
                                 [1.125, 5.04] 1.125 5.040 2.382688
                                                                        0.849
        3
                 New_HDI[T.TH]
                                [1.959, 6.424] 1.959 6.424 3.548975 0.004
[5090]: forest_v3
[5090]:
                                                          hl
                          coef
                                            CI
                                                   11
                                                                    OR
                                                                         pval
             Réf (homme/HDI B)
                                [0.518, 1.931]
                                                0.000
                                                      0.000
                                                                   1.0 0.157
          Gender[T.une femme]
                                [0.374, 1.099]
                                                0.374
                                                       1.099
                                                                        0.053
        1
                                                              0.641167
        2
                 New_HDI[T.I]
                                [0.367, 1.907]
                                                0.367
                                                       1.907
                                                              0.837539
                                                                        0.813
                                [0.334, 1.297] 0.334
        3
                 New HDI[T.TH]
                                                      1.297 0.658517 0.311
[5091]: for version in [forest_v1, forest_v2, forest_v3]:
            # Données de la régression logistique
            odds_ratios = version["OR"].tolist()
            ci = list(zip(version["ll"], version["hl"]))
            ci_inf = version["ll"].astype(str)
            ci_sup = version["hl"].astype(str)
            labels = version["coef"] + " (" + ci_inf + " - " + ci_sup + ", p=" +__
         ⇔version["pval"].astype(str)
            # Création du forest plot
            fig, ax = plt.subplots()
            # OR, intervalles de confiance
            for i, (or_val, (ci_low, ci_high), label) in enumerate(zip(odds ratios, ci,_
         →labels)):
                ax.plot([ci_low, ci_high], [i, i], color="black", linewidth=2)
                ax.plot(or_val, i, 'ro')
            # Réglages des axes
            ax.set xlim(left=0.5)
            ax.set_yticks(range(len(labels)))
            ax.set_yticklabels(labels)
            ax.set_xlabel('Odds Ratios')
            ax.axvline(1, color='black', linestyle='--')
            ax.spines["top"].set_visible(False)
            ax.spines["left"].set_visible(False)
            ax.spines["right"].set_visible(False)
            plt.title('Forest Plot of Odds Ratios')
            plt.show()
```







```
[5092]: # Regression de Poisson
        model = []
        for n, version in enumerate([df_exam_v1, df_exam_v2, df_exam_v3]):
            model.append(glm(formula=formula, data=version, family=sm.families.
         →Poisson()))
[5093]: # résultats de la fonction logistic par itération
        result_v1 = model[0].fit()
        result_v2 = model[1].fit()
        result_v3 = model[2].fit()
[5094]: # Calcul des odds-ratio, p-value et ci pour chaque itération
        full_odds_r, full_pvalues, full_ci = [], [], []
        for n, version in enumerate([result_v1, result_v2, result_v3]):
            # OR
            odds = np.exp(version.params).round(3)
            odds_r = odds / odds["Intercept"]
            odds_r.name = mooc[n]
            full_odds_r.append(odds_r)
            # p-value
            p_values = version.pvalues.round(3)
            p_values.name = mooc[n]
            full_pvalues.append(p_values)
            # interval de confiance (ci)
            ci = version.conf_int(alpha=0.05) # intervalle à 95 %
            sup = np.exp(ci[1]) / np.exp(ci.loc["Intercept", 0])
            inf = np.exp(ci[0]) / np.exp(ci.loc["Intercept", 1])
            ci = "[" + inf.round(3).astype(str) + ", " + sup.round(3).astype(str) + "]"
            ci.name = mooc[n]
```

```
full_ci.append(ci)
[5095]: tab_coef = pd.concat([pd.DataFrame(full_odds_r).T, pd.DataFrame(full_pvalues).
                   →T, pd.DataFrame(full_ci).T])
[5096]: index = pd.MultiIndex.from_arrays([["odds-ratio", "odds-ratio", 
                  ⇔"odds-ratio",
                                                                                           "p-value", "p-value", "p-value",
                                                                                           "ci", "ci", "ci", "ci"],
                                                                                          tab_coef.index], names=["type", "coef"])
[5097]: tab_full = pd.DataFrame({"V1": list(tab_coef["V1"]), "V2": [
                  tab_full.reset_index(inplace=True)
                tab_full.set_index(["type"], inplace=True)
[5098]: ci_v1 = tab_full.loc["ci", ["coef", "V1"]]
                or_v1 = tab_full.loc["odds-ratio", ["coef", "V1"]]
                pval_v1 = tab_full.loc["p-value", ["coef", "V1"]]
                ci_v2 = tab_full.loc["ci", ["coef", "V2"]]
                or_v2 = tab_full.loc["odds-ratio", ["coef", "V2"]]
                pval_v2 = tab_full.loc["p-value", ["coef", "V2"]]
                ci_v3 = tab_full.loc["ci", ["coef", "V3"]]
                or v3 = tab full.loc["odds-ratio", ["coef", "V3"]]
                pval_v3 = tab_full.loc["p-value", ["coef", "V3"]]
[5099]: ci_v1.rename(columns={'V1': 'CI'}, inplace=True)
                ci_v2.rename(columns={'V2': 'CI'}, inplace=True)
                ci_v3.rename(columns={'V3': 'CI'}, inplace=True)
                or_v1.rename(columns={'V1': 'OR'}, inplace=True)
                or_v2.rename(columns={'V2': 'OR'}, inplace=True)
                or_v3.rename(columns={'V3': 'OR'}, inplace=True)
                pval_v1.rename(columns={'V1': 'pval'}, inplace=True)
                pval_v2.rename(columns={'V2': 'pval'}, inplace=True)
                pval_v3.rename(columns={'V3': 'pval'}, inplace=True)
[5100]: # Extraction des bornes inférieure et supérieure des CI
                ci_v1[["ll", "hl"]] = ci_v1["CI"].str.strip("[]").str.split(",", expand=True).
                  →astype(float)
                ci_v2[["ll", "hl"]] = ci_v2["CI"].str.strip("[]").str.split(",", expand=True).
                   →astype(float)
                ci_v3[["11", "h1"]] = ci_v3["CI"].str.strip("[]").str.split(",", expand=True).
                   →astype(float)
```

```
[5101]: # Tableaux des valeurs pour créer le forestplot
        forest_v1 = ci_v1.merge(or_v1, on="coef").merge(pval_v1, on="coef")
        forest_v2 = ci_v2.merge(or_v2, on="coef").merge(pval_v2, on="coef")
        forest_v3 = ci_v3.merge(or_v3, on="coef").merge(pval_v3, on="coef")
[5102]: # Renommage de l'intercept
        forest v1.iloc[0, 0] = "Réf (homme/HDI B)"
        forest_v2.iloc[0, 0] = "Réf (homme/HDI B)"
        forest_v3.iloc[0, 0] = "Réf (homme/HDI B)"
[5103]: # Mise à zero des intervalle de confiance de l'intercept
        forest_v1.loc[0, "11"] = 0
        forest_v1.loc[0, "hl"] = 0
        forest_v2.loc[0, "11"] = 0
        forest_v2.loc[0, "hl"] = 0
        forest_v3.loc[0, "11"] = 0
        forest_v3.loc[0, "hl"] = 0
[5104]: for version in [forest_v1, forest_v2, forest_v3]:
            # Données de la régression logistique
            odds_ratios = version["OR"].tolist()
            ci = list(zip(version["ll"], version["hl"]))
            ci_inf = version["ll"].astype(str)
            ci_sup = version["hl"].astype(str)
            labels = version["coef"] + " (" + ci inf + " - " + ci sup + ", p=" +11
         ⇔version["pval"].astype(str)
            # Création du forest plot
            fig, ax = plt.subplots()
            # OR, intervalles de confiance
            for i, (or_val, (ci_low, ci_high), label) in enumerate(zip(odds_ratios, ci,_
         ⇒labels)):
                ax.plot([ci_low, ci_high], [i, i], color="black", linewidth=2)
                ax.plot(or_val, i, 'ro')
            # Réglages des axes
            ax.set_xlim(left=0.5)
            ax.set_yticks(range(len(labels)))
            ax.set_yticklabels(labels)
            ax.set_xlabel('Odds Ratios')
            ax.axvline(1, color='black', linestyle='--')
            ax.spines["top"].set_visible(False)
            ax.spines["left"].set_visible(False)
            ax.spines["right"].set_visible(False)
            plt.title('Forest Plot of Odds Ratios')
            plt.show()
```

